

Cuando los datos no podían con la realidad: COVID-19

Exploración del repositorio de casos confirmados de Johns Hopkins (22 ene 2020 – 9 mar 2023): limpieza, análisis temporal y visualización comparativa de una pandemia en 201 países.

Luis Javier Rubio Hernández

El problema detrás del problema

Cuando empecé a trabajar con este dataset, lo primero que me llamó la atención no fue la magnitud de los números, sino la arquitectura del archivo: 289 filas, 1.147 columnas, formato ancho. Cada columna era una fecha. Cada celda, un conteo *acumulado*, no diario. Esa distinción tiene consecuencias directas: si sumas una serie acumulada por mes, el resultado siempre favorece los meses más recientes, sin importar la epidemiología real. El primer paso era diferenciar la serie, calcular incrementos diarios, recortar negativos. Solo entonces los datos podían hablar con honestidad.

676,6 M

casos confirmados acumulados a nivel mundial

Fuente: CSSEGISandData / Johns Hopkins University · al 9 de marzo de 2023

201 PAÍSES / TERRITORIOS	1.143 DÍAS DE REGISTRO	Ene 2022 MES PICO GLOBAL	90,5 M CASOS ESE MES
------------------------------------	----------------------------------	------------------------------------	--------------------------------


El mes que nadie esperaba: Ómicron en enero de 2022

Enero de 2022 registró más de 90,5 millones de casos nuevos a nivel global, el 13,4 % del total acumulado de tres años de pandemia concentrado en 31 días. Los cuatro meses siguientes en el ranking también corresponden a 2022. La pandemia no fue una ola: fue una serie de escalones, con el más alto muy al final.

El pico no fue en 2020. Fue en enero de 2022, impulsado por Ómicron. En ese mes, EE. UU. aportó 20,3 M de casos —el 22,5 % del total global del mes—, seguido de Francia (9,2 M) e India (6,6 M).

Top 5 meses por casos nuevos — nivel mundial

Incrementos diarios acumulados por mes · Fuente: Johns Hopkins University



#	País	Casos nuevos (ene 2022)	% del mes
1	Estados Unidos	20.336.435	22,5 %
2	Francia	9.188.713	10,1 %
3	India	6.607.920	7,3 %
4	Italia	4.857.433	5,4 %
5	Reino Unido	4.420.003	4,9 %


Tres países, tres historias distintas

El mes pico global de enero de 2022 esconde una heterogeneidad que una tabla no puede mostrar. EE. UU. mantuvo una carga sostenida con un pico dramático en enero de 2022 (Ómicron). India vivió un pico agudo y breve en mayo de 2021 (Delta) con una reducción igualmente rápida. Francia mostró repuntes sucesivos coherentes con las oleadas europeas.

Tres patrones epidemiológicos distintos. Esta heterogeneidad temporal no es visible en ninguna tabla de totales. Requería una representación gráfica para hacerse perceptible.

Casos nuevos por mes — EE. UU., India y Francia (millones)

Ene 2020 – Feb 2023 · Fuente: Johns Hopkins University




La asimetría global: cinco países, 39 % de la pandemia

Al cierre del dataset los cinco países con más casos acumulados —EE. UU., India, Francia, Alemania y Brasil— concentran el 38,97 % del total mundial. Pero el dato más revelador está en el 61 % restante: más de 190 países distribuyen el resto. La pandemia fue verdaderamente planetaria; cualquier análisis limitado al top 5 pierde más de la mitad de la historia.

Casos acumulados — Top 5 países

Al 9 de marzo de 2023 · Fuente: Johns Hopkins University



La trampa del dato reportado: Corea del Norte

El país con el menor número de casos reportados al cierre es **Corea del Norte**, con exactamente un caso acumulado. Ese número no describe su epidemiología: describe su política de comunicación. Las propias autoridades norcoreanas reconocieron internamente cerca de 4,77 millones de personas con síntomas febriles entre abril y agosto de 2022.

Dato reportado ≠ fenómeno real. Esta distinción es fundamental en ciencia de datos con fuentes secundarias. La pregunta correcta no es "¿cuántos casos tuvo?" sino "¿cuántos reportó al repositorio?". Son preguntas distintas con respuestas distintas.

Lo que aprendí transformando un dataset de 676 millones de registros

El mayor desafío técnico no fue la escala sino la estructura. La diferencia entre datos acumulados y datos diarios cambia completamente la respuesta a una pregunta aparentemente simple. Los gráficos de series de tiempo no son decoración: son el único instrumento capaz de hacer visible la heterogeneidad temporal de una pandemia. Y Corea del Norte me recuerda que la calidad de un dataset no se mide solo por su cobertura, sino por la honestidad de los reportantes.

Este análisis forma parte del caso COVID-19 desarrollado en el curso de Gestión de Datos de la Maestría en Ciencia de Datos · PUJ Cali · Grupo B, 2026-1.

Fuentes

Dong, E., Du, H., & Gardner, L. (2020). An interactive web-based dashboard to track COVID-19 in real time. *The Lancet Infectious Diseases*, 20(5), 533–534.

CSSEGISandData (2023). *COVID-19 Data Repository – CSSE at Johns Hopkins University*.
github.com/CSSEGISandData/COVID-19

Knaflitz, C. N. (2015). *Storytelling with Data*. Wiley.