
Segmentación de clientes en marketing directo

Análisis estadístico descriptivo y exploratorio de una campaña piloto
2,220 clientes · 37 variables · R + bookdown + imputación múltiple

Luis Javier Rubio Hernández

Matemático · Magíster en Matemáticas · Estudiante de Maestría en Ciencia de Datos

Sinopsis

Con el fin de optimizar la rentabilidad y fundamentar futuros modelos predictivos, se analiza una base de datos resultante de una campaña piloto de marketing directo. El estudio se basó en el contacto telefónico a una muestra aleatoria de clientes para ofrecer un nuevo dispositivo, registrando con precisión su nivel de aceptación. Este proceso de caracterización y segmentación permite distinguir los rasgos de los clientes que respondieron positivamente frente a los que no, facilitando una toma de decisiones basada en datos.


Objetivo general

Caracterizar estadísticamente los perfiles de clientes que aceptaron y rechazaron la oferta del nuevo dispositivo en la campaña piloto, mediante análisis descriptivo y exploratorio de datos.

Objetivos específicos

1. Cuantificar y tratar los valores atípicos, inconsistencias y datos faltantes presentes en la base de datos mediante técnicas estadísticas apropiadas.
2. Evaluar el mecanismo de generación de datos faltantes mediante pruebas estadísticas.
3. Identificar y caracterizar las variables demográficas, económicas y de comportamiento de compra que diferencian a los clientes que aceptaron la oferta de aquellos que la rechazaron.
4. Establecer patrones de comportamiento y relaciones bivariadas entre variables que permitan describir el perfil de clientes propensos a aceptar ofertas de marketing directo.

Distribución de Response



1. Datos

La base de datos contiene información detallada sobre el perfil demográfico y el comportamiento de consumo de **2,220 clientes** y **37 variables**. Cada entrada documenta variables clave relacionadas con el estatus socioeconómico, la composición familiar, los hábitos de gasto y la respuesta a campañas de marketing. La información incluye ingreso anual (Income), presencia de menores en el hogar (Kidhome, Teenhome), antigüedad del cliente (Customer_Days), edad (Age), comportamiento de compra por canal (tienda, catálogo, web), gasto desglosado por categorías (prefijo Mnt) y respuesta a cinco campañas previas (AcceptedCmp1-5).

Clasificación de variables

Variable	Descripción	Naturaleza
Income	Ingreso anual del cliente	Cuantitativa continua
Kidhome / Teenhome	Número de niños / adolescentes en hogar	Cuantitativa discreta
Recency	Días desde la última compra	Cuantitativa discreta
MntWines	Monto gastado en vinos	Cuantitativa continua
MntFruits	Monto gastado en frutas	Cuantitativa continua
MntMeatProducts	Monto gastado en productos cárnicos	Cuantitativa continua
MntFishProducts	Monto gastado en pescado	Cuantitativa continua
MntSweetProducts	Monto gastado en dulces	Cuantitativa continua
MntGoldProds	Monto gastado en productos premium	Cuantitativa continua
NumDealsPurchases	Compras con descuento	Cuantitativa discreta
NumWebPurchases	Compras vía web	Cuantitativa discreta
NumCatalogPurchases	Compras por catálogo	Cuantitativa discreta
NumStorePurchases	Compras en tienda física	Cuantitativa discreta
NumWebVisitsMonth	Visitas web en el último mes	Cuantitativa discreta
AcceptedCmp1-5	Aceptación de campañas previas	Cualitativa binaria
Response	Respuesta a la campaña piloto	Cualitativa binaria
Age / Customer_Days	Edad / Antigüedad del cliente	Cuantitativa discreta
marital_*	Estado civil (5 dummies)	Cualitativa binaria
education_*	Nivel educativo (5 dummies)	Cualitativa binaria
MntTotal	Gasto total (sin MntGoldProds)	Cuantitativa continua
MntRegularProds	Gasto en productos regulares	Cuantitativa continua

Total: 2 continuas, 17 discretas, 18 binarias. Variable objetivo: Response.




Figura 1. Tasa de aceptación por campaña. Las 5 campañas previas no superan el 7.5%; la campaña piloto (Response) alcanza 15.4%.

2. Procesamiento

2.1 Identificación y eliminación de duplicados

Concepto	Valor
Total de datos original	2,220

Concepto	Valor
Total de duplicados	179
Porcentaje de duplicados	8.06%
Total sin duplicados	2,041

Se identificaron 179 registros duplicados (8.06%), correspondientes a clientes con información idéntica en todas las variables. Su presencia introduce sesgo en los estimadores, inflando artificialmente el tamaño muestral y violando el supuesto de independencia (Barnett & Lewis, 1994).

2.2 Estadísticos descriptivos y detección de atípicos

Se aplicó el método IQR (Tukey, 1977) para la detección de valores atípicos:

$$IQR = Q_3 - Q_1 ; L_{inf} = Q_1 - 1.5 \cdot IQR ; L_{sup} = Q_3 + 1.5 \cdot IQR$$

Variable	Mín	Media	DE	Q1	Mediana	Q3	Máx
Income	17,300	516,809	207,353	352,460	514,120	681,480	1,137,340
MntWines	0	301.5	332.9	24	174	499	1,493
MntFruits	0	26.3	39.8	2	8	33	199
MntMeat	0	166.0	219.8	16	68	230	1,725
MntFish	0	37.6	54.8	3	12	50	259
MntSweet	0	27.3	41.6	1	8	34	262
MntGold	0	43.9	51.7	9	24	56	321
MntTotal	4	564.5	577.8	55	343	965	2,491
Age	25	51.4	13.0	43	50	61	240
Recency	0	48.9	28.9	24	49	74	99
Customer_Days	2,159	2,511	202.6	2,337	2,510	2,688	2,858

Tabla 2. Estadísticos descriptivos pre-tratamiento.




Figura 2. Variables de gasto (MntSweet, MntFruits, MntFish, MntGold, MntMeat) superan el 5%. Estos atípicos representan el segmento premium y fueron conservados (Rousseeuw & Hubert, 2011).

2.3 Detección y tratamiento de inconsistencias

Se detectaron inconsistencias estructurales en tres variables que violan el dominio teórico:

Variable	Criterio de validez	N° inválidos	Valores detectados
MntRegularProds	Monto ≥ 0	3	-151, -166, -283
Age	$0 < \text{Edad} \leq 110$ años	2	240
marital_Divorced	Valor $\in \{0, 1\}$	6	100

Según Osborne y Overbay (2004), inconsistencias que violan restricciones del dominio deben eliminarse por completo. Se eliminaron 11 registros (0.54% de 2,041), resultando en **2,030 observaciones válidas**.

Impacto del tratamiento

Momento	Variable	Media	Mediana	DE	Q1	Q3
Antes	Age	51.35	50.0	13.04	43	61
Después	Age	51.17	50.0	11.65	43	61
Antes	MntRegularProds	520.59	288.0	555.88	42	886
Después	MntRegularProds	522.72	290.5	555.82	42	887

Para Age, la desviación estándar disminuyó de 13.04 a 11.65 (reducción del 10.6%), evidenciando que el registro con edad 240 generaba sobreestimación de variabilidad. La mediana permaneció en 50. Para MntRegularProds, la media aumentó apenas 0.4% y la DE se mantuvo constante.




Figura 3. Comparación de media ± DE antes y después del tratamiento.

2.4 Validación estadística de la depuración

La eliminación del 8.56% de datos (190 registros) fue validada mediante tres criterios:

Variable	Estadístico D	p-valor	Variable	Estadístico D	p-valor
Income	0.0065	1.000	MntFish	0.0054	1.000
MntWines	0.0029	1.000	MntSweet	0.0037	1.000
MntFruits	0.0034	1.000	MntGold	0.0061	1.000
MntMeat	0.0045	1.000	MntTotal	0.0035	1.000

Prueba de Kolmogorov-Smirnov: estadísticos D extremadamente bajos, p = 1.0 en todas.

Norma de Frobenius entre matrices de correlación: **0.056**. Valor extraordinariamente bajo que confirma preservación de la estructura correlacional completa.




Figura 4. Estadísticos D de la prueba KS por variable.

Comparación de medias antes y después

Variable	Media original	Media limpia	DE original	DE limpia	Cambio relativo (%)
Income	516,536	517,963	207,041	206,598	0.28
MntWines	301.1	302.1	331.6	332.3	0.35
MntFruits	26.6	26.5	40.2	39.9	0.52
MntMeat	165.8	166.7	218.2	220.1	0.57
MntFish	37.7	37.8	54.8	54.9	0.05
MntSweet	27.1	27.4	41.1	41.7	1.25
MntGold	44.3	43.5	52.1	50.8	1.85
MntTotal	563.5	566.2	575.8	578.1	0.48

Todos los cambios relativos inferiores al 2%. La depuración no introdujo sesgo.

3. Tratamiento de datos faltantes

3.1 Identificación

Variable	Cantidad NA	Porcentaje (%)
Income	66	3.25
MntWines	20	0.99

Solo dos variables presentan ausencias. Ambas proporciones están por debajo del umbral del 5% señalado por Little y Rubin (2002). El resto de variables no presentan datos faltantes.




Figura 5. Izquierda: porcentaje de faltantes. Derecha: estabilidad de la media de Income entre las 5 imputaciones PMM.

3.2 Evaluación del mecanismo generador

Para evaluar si los datos faltan completamente al azar (MCAR), se aplica el test de Little (1988).

Estadístico χ^2	Grados de libertad	p-valor	Decisión
41.5232	20	0.0032	Se rechaza H_0

H_0 : Los datos faltantes son MCAR. H_1 : Los datos faltantes NO son MCAR.

Con $p = 0.0032 < 0.05$ se rechaza H_0 . Dado el bajo porcentaje de ausencia (<5%) y la ausencia de evidencia de MNAR, se asume un mecanismo **MAR (Missing At Random)**, justificando la imputación múltiple (Rubin, 1987).

3.3 Selección del método de imputación

Se excluyen variables con colinealidad perfecta ($VIF = \infty$): $MntTotal = MntWines + MntFruits + MntMeatProducts + MntFishProducts + MntSweetProducts$; $MntRegularProds = MntTotal - MntGoldProds$; $AcceptedCmpOverall = AcceptedCmp1 + \dots + AcceptedCmp5$. Se comparan tres métodos ($m = 5, 10$ iteraciones):

Método	Income media	Income DE	Income DE entre	MntWines media	MntWines DE	MntWines DE entre	Δ media Income	Δ DE Income	Δ media Wines	Δ DE Wines
PMM	518,783	206,622	215.8	305.6	334.6	0.36	0.52%	0.52%	1.86%	1.25%
CART	518,226	206,494	285.4	305.6	334.8	0.61	0.41%	0.46%	1.87%	1.32%

Método	Income media	Income DE	Income DE entre	MntWines media	MntWines DE	MntWines DE entre	Δ media Income	Δ DE Income	Δ media Wines	Δ DE Wines
Ridge	518,937	206,795	66.2	305.2	333.4	0.31	0.55%	0.61%	1.72%	0.89%

PMM presenta mayor estabilidad y preservación de momentos.

Preservación de correlaciones

Método	Income~MntWines	Income~Age	MntWines~Age
Observado	0.727	0.217	0.168
PMM	0.726	0.211	0.166
CART	0.728	0.213	0.166
Ridge	0.728	0.210	0.167

Los tres métodos reproducen fielmente la estructura correlacional. Se selecciona **PMM con regularización ridge** (van Buuren, 2018).

Estabilidad entre imputaciones

Imputación	Media Income	Media MntWines
1	518,768	305.95
2	518,909	305.80
3	519,078	305.62
4	518,563	305.30
5	518,597	305.08

Baja variabilidad entre las 5 imputaciones confirma estabilidad del método.

4. Resultados

4.1 Estadísticos descriptivos post-procesamiento

Variable	Media	Mediana	DE	IQR	Asimetría
Income	518,768	515,500	206,491	329,175	0.01
MntTotal	607.8	401.0	601.2	980	0.85
Age	51.2	50.0	11.7	18	0.10
Recency	48.9	49.0	28.9	50	0.00
NumWebVisitsMonth	5.3	6.0	2.4	4	0.24
Customer_Days	2,511	2,511	202.8	352	-0.01

Las variables económicas (Income, MntTotal) presentan asimetría positiva, coherente con distribuciones de ingresos y gasto. Customer_Days es simétrica, reflejando antigüedad uniforme.

Distribución de variables categóricas

Variable	Categoría	Frec. relativa	Frec. absoluta
Response	0 (No aceptó)	0.846	1,718
Response	1 (Aceptó)	0.154	312
education_Graduation	1	0.502	1,020
marital_Married	1	0.388	787
Kidhome	0	0.578	1,174
Kidhome	1	0.401	815
Kidhome	2	0.020	41

Desbalance en Response (proporción 85:15). Predominio de clientes con educación superior (~50%), casados (~39%), y sin hijos (~58%).

4.2 Matriz de correlaciones




Figura 6. Alta correlación Income–MntWines (0.73), MntMeat–MntTotal (0.77), MntWines–MntTotal (0.82). Recency independiente del resto. WebVisits presenta correlaciones negativas con variables de gasto.

4.3 Variables numéricas por grupo Response

Se aplicaron pruebas de **Mann-Whitney** (no paramétrica, adecuada para distribuciones asimétricas). El tamaño del efecto se cuantifica mediante r_{rb} (rank-biserial). Umbrales: $|r| < 0.1$ despreciable, 0.1–0.3 pequeño, 0.3–0.5 moderado, ≥ 0.5 grande.

Variable	Media R=0	Media R=1	Mediana R=0	Mediana R=1	DE R=0	DE R=1	p-valor	r	Magnitud
Income	503,789	601,254	503,700	637,810	197,994	231,698	<0.001	0.257	Pequeño
MntTotal	540.7	977.4	315.5	1,057.5	553.0	712.7	<0.001	0.381	Moderado
Age	51.3	50.5	50.0	49.0	11.5	12.3	0.258	0.040	Despreciable
Recency	51.5	34.7	52.0	29.0	28.5	27.3	<0.001	0.334	Moderado
WebVisits	5.3	5.3	6.0	6.0	2.4	2.6	0.741	0.012	Despreciable
Cust_Days	2,495	2,603	2,487	2,646	199.0	199.8	<0.001	0.307	Moderado

MntTotal: La señal más marcada del análisis. Los clientes que aceptaron presentan un gasto medio que prácticamente duplica al del grupo que rechazó (mediana \$1,058 vs \$316). Mayor tamaño del efecto entre todas las variables numéricas ($r = 0.381$). Principal discriminador conductual.

Income: Ingreso medio sustancialmente mayor en aceptantes. Diferencia relativa del 19% entre medias. La correlación entre Income y MntTotal ($r = 0.73$) implica que ambas capturan parcialmente la misma dimensión latente de capacidad económica.

Recency: Los aceptantes compraron más recientemente: mediana 29 días vs 52 días ($r = -0.334$). La actividad transaccional reciente refleja mayor vínculo con la marca y mayor receptividad.

Customer_Days: Mayor antigüedad en aceptantes ($r = 0.307$). Recency y Customer_Days capturan dimensiones temporales complementarias: actividad reciente vs lealtad acumulada.

Age: Sin diferencia significativa ($p = 0.258$, $r = 0.040$). La edad no constituye factor discriminante.

WebVisits: Sin diferencia significativa ($p = 0.741$, $r = 0.012$). La interacción digital pasiva no se traduce en propensión a aceptar ofertas.




Figura 7. Jerarquía de tamaños del efecto. MntTotal, Recency y Customer_Days superan el umbral moderado (0.3).




Figura 8. Comparación de medianas por grupo Response.

4.4 Variables categóricas por grupo Response

Prueba **Chi-cuadrado de independencia** con **V de Cramér**. Umbrales (1 gl): $V < 0.1$ despreciable, $0.1-0.3$ pequeño, $0.3-0.5$ moderado, ≥ 0.5 grande.

Variable	χ^2	gl	p-valor	V de Cramér	Magnitud
education_Graduation	3.08	1	0.0791	0.040	Despreciable
marital_Married	12.92	1	0.0003	0.081	Despreciable
Kidhome	13.55	2	0.0011	0.082	Despreciable

Proporción de aceptación según Kidhome

Kidhome	Nº aceptaron	Proporción aceptación
0	208	17.7%
1	102	12.5%
2	2	4.9%

Hogares sin hijos presentan tasa del 17.7% vs 12.5% con un hijo y 4.9% con dos. No obstante, V de Cramér indica asociación despreciable. **education_Graduation** ($p = 0.079$) y **marital_Married** ($p = 0.0003$, $V = 0.081$) tampoco presentan asociación de magnitud práctica relevante.




Figura 9. Proporción de aceptación por categoría.

5. Discusión de resultados

El análisis bivariado permite establecer una **jerarquía de relevancia** entre las variables analizadas en relación con la respuesta a la campaña:

Primer nivel — Comportamiento transaccional: MntTotal e Income constituyen los principales diferenciadores. El gasto acumulado exhibe el mayor tamaño del efecto, seguido por el ingreso. La campaña resulta más efectiva en el segmento de clientes de alto valor, cuyo comportamiento de compra previo predice de manera consistente su propensión a aceptar. La correlación entre Income y MntTotal ($r = 0.73$) implica que ambas capturan parcialmente la misma dimensión latente de capacidad económica — aspecto que deberá considerarse en la selección de predictores para el modelado.

Segundo nivel — Dimensión temporal: Recency ($r = -0.334$) y Customer_Days ($r = 0.307$) capturan dimensiones complementarias: actividad reciente (mayor vínculo activo) y lealtad acumulada (permanencia con la marca). Ambas con efecto moderado y $p < 0.001$.

Tercer nivel — Estructura del hogar: Kidhome muestra asociación débil pero significativa. Hogares sin hijos presentan mayor propensión, posiblemente mediada por disponibilidad de ingreso discrecional. Podría aportar capacidad explicativa complementaria en un modelo multivariante que controle simultáneamente por ingreso.

Variables no discriminantes: Edad, nivel educativo, estado civil y frecuencia de visitas web no presentan capacidad discriminante. El perfil del cliente respondiente se define por su patrón de consumo y actividad transaccional reciente, no por características sociodemográficas — hallazgo consistente con la literatura en marketing directo.

6. Conclusiones

1. La depuración de 179 duplicados y 11 inconsistencias estructurales fue validada estadísticamente: las pruebas KS arrojaron $p = 1.0$ en todas las variables y la norma de Frobenius entre matrices de correlación fue 0.056, confirmando que ni las distribuciones marginales ni la estructura correlacional fueron distorsionadas.
2. El test de Little rechazó el mecanismo MCAR ($\chi^2 = 41.52$, $p = 0.003$). La imputación múltiple por PMM ($m = 5$) fue seleccionada sobre CART y Ridge por su estabilidad entre imputaciones y preservación fiel de las correlaciones observadas (Income~MntWines: 0.727 observado vs 0.726 imputado).
3. El gasto acumulado (MntTotal) es el principal discriminador entre clientes que aceptan y rechazan la oferta: la mediana de gasto de los aceptantes prácticamente triplica la de los no aceptantes (\$1,058 vs \$316), con un tamaño del efecto moderado ($r = 0.381$).
4. La recencia de compra y la antigüedad del cliente capturan dimensiones temporales complementarias — actividad reciente y lealtad acumulada — ambas con efecto moderado ($r = 0.334$ y $r = 0.307$ respectivamente) y altamente significativas ($p < 0.001$).
5. Las variables demográficas (edad, educación, estado civil) no presentan capacidad discriminante. El perfil del cliente respondiente se define por comportamiento transaccional, no por demografía.

6. La interacción digital pasiva (visitas web) no se traduce en propensión a aceptar. Esto sugiere que el engagement real no se mide por frecuencia de visitas al sitio.
7. El pipeline completo — depuración con validación, evaluación del mecanismo de faltantes, imputación múltiple, y análisis bivariado con pruebas no paramétricas y tamaños del efecto — constituye una base sólida para la construcción de modelos predictivos supervisados. Las variables MntTotal, Income, Recency y Customer_Days son los candidatos naturales para la selección de predictores.

7. Referencias

- Barnett, V., & Lewis, T. (1994). *Outliers in Statistical Data* (3rd ed.). Wiley.
- Belsley, D. A., Kuh, E., & Welsch, R. E. (1980). *Regression Diagnostics*. Wiley.
- Centro Magis (2025). *Material del curso Métodos y Simulación, versión 01-2025*. Maestría en Ciencia de Datos, Pontificia Universidad Javeriana Cali.
- Little, R. J. (1988). A test of missing completely at random for multivariate data with missing values. *Journal of the American Statistical Association*, 83(404), 1198–1202.
- Little, R. J., & Rubin, D. B. (2002). *Statistical Analysis with Missing Data* (2nd ed.). Wiley.
- Osborne, J. W., & Overbay, A. (2004). The power of outliers. *Practical Assessment, Research & Evaluation*, 9(6), 1–12.
- R Core Team (2024). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing, Vienna, Austria.
- Rousseeuw, P. J., & Hubert, M. (2011). Robust statistics for outlier detection. *WIREs: Data Mining and Knowledge Discovery*, 1(1), 73–79.
- Rubin, D. B. (1987). *Multiple Imputation for Nonresponse in Surveys*. Wiley.
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- van Buuren, S. (2018). *Flexible Imputation of Missing Data* (2nd ed.). Chapman & Hall/CRC.
- van Buuren, S., & Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3), 1–67.
- von Hippel, P. T. (2009). How to impute interactions, squares, and other transformed variables. *Sociological Methodology*, 39(1), 265–291.

Competencias demostradas en este análisis

Limpieza y validación estadística de datos · Detección de inconsistencias y atípicos (IQR) · Pruebas no paramétricas (Kolmogorov-Smirnov, Mann-Whitney, Chi-cuadrado) · Evaluación de mecanismo de faltantes (test de Little) · Imputación múltiple (PMM, CART, Ridge) · Tamaños del efecto (r rank-biserial, V de Cramér) · Norma de Frobenius · Comunicación de hallazgos basada en datos · R · bookdown

Luis Javier Rubio Hernández

Matemático · Magíster en Matemáticas · Estudiante de Maestría en Ciencia de Datos