

¿Qué significa, exactamente, que una máquina aprenda?

Las cuatro piezas de un modelo, la función de costo, el descenso del gradiente y el proceso completo — con el rigor intacto y sin dar nada por sabido.

Luis Javier Rubio Hernández

Este documento reúne los fundamentos del aprendizaje automático clásico: qué significa que un modelo aprenda, qué piezas lo componen, cómo se mide el error, cómo se resuelve el problema de optimización que resulta y qué proceso ordena el trabajo completo. Está dirigido a quien quiera estudiar estos temas con el detalle matemático a la vista, sin más requisitos que el cálculo y el álgebra lineal elementales.

Cada resultado se enuncia con sus hipótesis, y donde una afirmación frecuente es imprecisa se dice expresamente en lugar de simplificarla. El tratamiento parte de un texto introductorio de referencia y se completa, allí donde ese texto no alcanza, con las obras clásicas citadas al final; la nota de método detalla el origen de cada contenido y de cada figura.

Toda fórmula que aparece aquí va seguida de su lectura en palabras. La notación no está para impresionar a nadie: está porque es la única manera de decir ciertas cosas sin ambigüedad.

4

piezas definen un modelo:
datos, familia, costo, algoritmo

5

etapas en el proceso,
leídas contra CRISP-DM

2

problemas predictivos:
regresión y clasificación

CÓMO ESTÁ ORGANIZADO

I. Qué significa aprender — riesgo empírico y riesgo esperado. II. Las cuatro piezas: los datos, la familia de modelos, la función de costo (con el error cuadrático medio en detalle) y el algoritmo (con el descenso del gradiente en detalle). III. Regresión y clasificación, con las métricas de evaluación. IV. Supervisado y no supervisado. V. El proceso completo, leído contra CRISP-DM. VI. El diseño de características. VII. Cuando el modelo falla. Al final, un anexo de notación, un glosario y las referencias.

Cada sección puede leerse por separado. Las figuras indican siempre su origen: si provienen de un cálculo, de datos sintéticos o si son ilustraciones conceptuales.

Qué significa aprender

Por qué el criterio de éxito está en los datos que el modelo nunca vio

El aprendizaje automático adopta un criterio de éxito que conviene enunciar antes que cualquier otra cosa, porque de él dependen todas las decisiones posteriores: un modelo no se juzga por reproducir los datos con los que fue construido, sino por acertar sobre datos que no participaron de su construcción. Esa exigencia, que suele presentarse de manera informal, tiene una traducción matemática exacta.


Supongamos que los pares (características, salida) se generan según una distribución de probabilidad desconocida. Lo que de verdad quisiéramos minimizar es el error promedio sobre esa distribución —el riesgo esperado—, pero solo disponemos de una muestra finita, y lo único que podemos calcular es el promedio sobre ella —el riesgo empírico:

$$R(f) = \mathbb{E}_{(x,y) \sim \mathcal{P}} [L(f(x), y)] \qquad \hat{R}(f) = \frac{1}{P} \sum_{p=1}^P L(f(x_p), y_p)$$

Cómo se lee. A la izquierda, el error que cometería el modelo en promedio sobre *todos* los casos posibles del fenómeno; es el número que nos importa y que nunca podremos calcular, porque no conocemos la distribución que genera los datos. A la derecha, el error promedio sobre los P casos que sí tenemos. Aprender consiste en usar el segundo con la esperanza de que se parezca al primero.

Esta sustitución tiene un nombre —minimización del riesgo empírico— y una garantía modesta pero precisa: si las observaciones son independientes y provienen de la misma distribución, entonces, *para una función f fijada de antemano*, el riesgo empírico es un estimador insesgado del riesgo esperado. La cláusula en cursiva es toda la dificultad del aprendizaje automático: en cuanto elegimos f mirando los mismos datos con los que la evaluamos, la garantía se rompe, y el error de entrenamiento empieza a ser un optimista sistemático.

De ahí sale la regla que ordena toda la disciplina: el conjunto con el que se entrena y el conjunto con el que se evalúa tienen que ser disjuntos. No es una precaución de laboratorio: es la única forma de que el número que reportamos signifique algo.




El ejemplo con el que abre el libro. Con dos características bien elegidas —tamaño de la nariz y forma de la oreja— gatos y perros ocupan regiones distintas del plano y basta una recta para separarlos. Ilustración conceptual: no son datos reales.

Las cuatro piezas

Tres definen el problema; la cuarta lo resuelve

Cuando se dice que alguien "entrenó un modelo", se están juntando en una sola frase cuatro decisiones independientes. Separarlas es lo más útil que puede hacerse al empezar: la mayoría de las discusiones confusas sobre aprendizaje automático son discusiones en las que dos personas hablan de piezas distintas.



Las tres primeras piezas convierten un problema del mundo en un problema de optimización bien planteado. La cuarta es el procedimiento que lo resuelve.

La distinción entre las tres primeras y la cuarta no es cosmética, y conviene decir con precisión cuánto importa. Si el problema de optimización resultante es convexo y tiene un único mínimo, el algoritmo no cambia la respuesta: cambia el camino, el tiempo y la precisión con que se llega a ella. Si el problema no es convexo —el caso de casi todos los modelos con muchos parámetros—, entonces el algoritmo y su punto de partida sí determinan a qué solución se llega, y dos ejecuciones pueden terminar en sitios distintos.

II.1 Los datos

La primera pieza es el conjunto de entrenamiento: P observaciones, cada una descrita por N características y acompañada de su salida.

$$\mathcal{D} = \{(x_p, y_p)\}_{p=1}^P, \quad x_p \in \mathbb{R}^N, \quad \mathbf{X} \in \mathbb{R}^{P \times (N+1)}$$

Cómo se lee. Cada observación es un par: un vector con N números que la describen y el valor que queremos aprender a predecir. Apiladas por filas —y con una primera columna de unos que da cabida al término independiente— forman la matriz de diseño $\mathbf{X}$, que es la forma en que los datos entran realmente a los cálculos.

II.2 La familia de modelos

La segunda pieza es el conjunto de funciones entre las que vamos a buscar. Elegir la familia es acotar de antemano las respuestas admisibles; el caso lineal es el más simple y, según el propio texto, el más frecuente cuando las características están bien diseñadas.

$$f(\mathbf{x}) = b + \mathbf{x}^\top \mathbf{w}, \quad b \in \mathbb{R}, \quad \mathbf{w} \in \mathbb{R}^N$$

Cómo se lee. La predicción es una suma ponderada de las características más una constante. Cada peso dice cuánto pesa una característica y en qué sentido; el término b desplaza la recta —o el plano— sin cambiar su inclinación. En total, $N + 1$ parámetros por determinar.

Conviene ver el objeto geométrico que hay detrás, porque explica por qué el mismo modelo sirve para dos problemas distintos: el conjunto de puntos donde la expresión se anula es un hiperplano; una recta si $N = 2$, un plano si $N = 3$, y así.

II.3 LA FUNCIÓN DE COSTO

El error cuadrático medio, con cuidado

La tercera pieza mide qué tan mal lo hace cada elección de parámetros. Hay que distinguir dos objetos que suelen nombrarse igual: la pérdida se calcula sobre una observación, y el costo es la agregación de las pérdidas sobre todo el conjunto. La pérdida más usada en regresión es el cuadrado del residuo:


$$L(\hat{y}, y) = (\hat{y} - y)^2, \quad r_p = f(x_p) - y_p$$

Cómo se lee. El residuo es la distancia vertical entre lo que el modelo predice y lo que realmente ocurrió. La pérdida lo eleva al cuadrado, con lo cual desaparece el signo —sobrestimar y subestimar cuestan igual— y los errores grandes pesan mucho más que los pequeños.

Al promediar las pérdidas sobre las P observaciones se obtiene el costo, que en este caso es exactamente el error cuadrático medio:

$$g(b, w) = \text{ECM} = \frac{1}{P} \sum_{p=1}^P (b + x_p^\top w - y_p)^2$$

Cómo se lee. Se calcula la predicción de cada observación, se le resta el valor verdadero, se eleva al cuadrado y se promedia. Un solo número que resume el desempeño de un par de parámetros sobre todo el conjunto. Cuanto más pequeño, mejor el ajuste.



Los residuos de un ajuste por mínimos cuadrados sobre diez puntos sintéticos. El ECM es el promedio de los cuadrados de esos diez segmentos; para esta recta vale 0,0361. Cálculo propio.


¿Por qué el cuadrado?

La pregunta tiene cuatro respuestas, y ninguna es "porque sí". Primero, el cuadrado es diferenciable en todos sus puntos, mientras que el valor absoluto no lo es en el origen — y la diferenciabilidad es lo que permite usar los métodos de la pieza 4. Segundo, el costo resultante es convexo, de modo que todo mínimo local es global. Tercero, en el caso lineal el mínimo tiene solución cerrada. Y cuarto, hay una razón estadística: si suponemos que la salida se genera como el modelo lineal más un error aleatorio normal, independiente entre observaciones y de varianza constante, entonces maximizar la verosimilitud *equivale* a minimizar la suma de cuadrados.


$$y_p = b + \mathbf{x}_p^\top \mathbf{w} + \varepsilon_p, \quad \varepsilon_p \sim \mathcal{N}(0, \sigma^2) \implies -\log \mathcal{L} = \frac{P}{2} \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \sum_{p=1}^P r_p^2$$

Cómo se lee. Si el ruido es normal, la log-verosimilitud cambiada de signo es una constante más la suma de residuos al cuadrado dividida por dos veces la varianza. Como la constante y la varianza no dependen de los parámetros, buscar el máximo de la verosimilitud y buscar el mínimo del ECM son literalmente el mismo problema. El cuadrado no es un capricho: es lo que corresponde bajo ese supuesto de ruido.

Y también hay que decir el precio. Elevar al cuadrado hace que una sola observación anómala pese enormemente, porque su contribución crece con el cuadrado de la distancia. Las alternativas habituales son la pérdida absoluta —más robusta, no diferenciable en el origen— y la de Huber, que se comporta como el cuadrado cerca de cero y como el valor absoluto lejos, quedándose con lo mejor de las dos.



Tres formas de castigar un residuo. La de Huber aparece reescalada para poder compararla en la misma escala. Curvas calculadas a partir de sus definiciones.



El precio del cuadrado, medido: al agregar un solo punto atípico a los diez originales, la pendiente estimada cae de 0,695 a 0,374 y el intercepto sube de 0,735 a 1,530. Ningún otro dato cambió. Cálculo propio por mínimos cuadrados.

Las dos acepciones de "error cuadrático medio"

Aquí hay una fuente de confusión que conviene despejar, porque la sigla se usa para dos objetos distintos. El primero es el que acabamos de definir: un promedio sobre una muestra, que se minimiza al entrenar. El segundo pertenece a la teoría de la estimación y es una *esperanza*, no un promedio muestral:

$$\text{ECM}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + [\text{Sesgo}(\hat{\theta})]^2$$

Cómo se lee. Mide qué tan lejos cae, en promedio sobre todas las muestras posibles, un estimador del valor verdadero que intenta estimar. Se descompone exactamente en dos términos: cuánto varía el estimador de una muestra a otra, y cuánto se desvía sistemáticamente del blanco. Es una identidad algebraica, no una aproximación.

La misma descomposición reaparece al analizar el error de predicción en un punto, y es la que explica por qué un modelo más flexible no es automáticamente mejor. Bajo el supuesto de que la salida se genera como una función determinista más un ruido de media cero y varianza constante, e independiente del ajuste:

$$\mathbb{E}[(y_0 - \hat{f}(x_0))^2] = \underbrace{\sigma^2}_{\text{irreducible}} + \underbrace{[\text{Sesgo}(\hat{f}(x_0))]^2}_{\text{rigidez}} + \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{inestabilidad}}$$

Cómo se lee. El error esperado en un punto nuevo tiene tres fuentes. La primera es el ruido del propio fenómeno y no hay modelo que la elimine. La segunda mide lo que se pierde por usar una familia demasiado rígida para la realidad. La tercera mide cuánto cambiaría la predicción si nos hubiera tocado otra muestra de entrenamiento. Reducir la segunda suele aumentar la tercera: ese intercambio es el problema central del oficio.

Cuando alguien diga "el ECM del modelo", vale la pena preguntar si habla del promedio sobre una muestra o de una esperanza teórica. Son objetos distintos, y solo uno de los dos se puede calcular con datos.

II.4 EL ALGORITMO

El descenso del gradiente

Las tres piezas anteriores dejan planteado un problema de minimización. La cuarta es el procedimiento que lo resuelve, y es una decisión aparte: el mismo problema admite varios métodos, y el mismo método sirve para muchos problemas distintos.

$$(b^*, w^*) = \underset{b \in \mathbb{R}, w \in \mathbb{R}^N}{\text{argmin}} g(b, w)$$

Cómo se lee. Buscamos el par de parámetros que hace más pequeño el costo. El asterisco marca la elección óptima, no un valor cualquiera.

Para el ECM con modelo lineal existe una fórmula cerrada. Escribiendo todos los parámetros en un solo vector y con la matriz de diseño:

$$\theta^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \quad \text{si } \text{rango}(\mathbf{X}) = N + 1$$

Cómo se lee. La solución exacta se obtiene con operaciones de álgebra lineal, sin iterar. La condición de la derecha es indispensable: si las columnas de la matriz de diseño son linealmente dependientes —por ejemplo, si una característica es combinación de otras— la matriz que hay que invertir es singular y la fórmula no aplica.

Si existe una fórmula cerrada, ¿para qué iterar? Por dos razones concretas. La inversión cuesta del orden de N^3 operaciones, lo que la vuelve impracticable cuando el número de características es grande. Y, sobre todo, porque para casi cualquier otro costo —el de la regresión logística, por ejemplo— no existe ninguna fórmula cerrada. Ahí es donde entra el método de primer orden por excelencia.

De dónde sale la regla

El gradiente es el vector de las derivadas parciales del costo respecto de cada parámetro. Su interpretación es geométrica: apunta en la dirección de máximo crecimiento local de la función. El desarrollo de Taylor de primer orden lo hace evidente:

$$g(\mathbf{w} + \mathbf{d}) = g(\mathbf{w}) + \nabla g(\mathbf{w})^\top \mathbf{d} + o(\|\mathbf{d}\|)$$

Cómo se lee. Para un desplazamiento pequeño, el costo cambia aproximadamente en el producto escalar entre el gradiente y la dirección del desplazamiento; el resto es de orden inferior y se vuelve despreciable a medida que el paso se acorta.

Si buscamos, entre todas las direcciones de longitud uno, la que más disminuye el costo, la desigualdad de Cauchy–Schwarz da la respuesta de inmediato:

$$\operatorname{argmin}_{\|\mathbf{d}\|=1} \nabla g(\mathbf{w})^\top \mathbf{d} = -\frac{\nabla g(\mathbf{w})}{\|\nabla g(\mathbf{w})\|}$$

Cómo se lee. La dirección de máximo descenso es exactamente la del gradiente cambiado de signo. No es una heurística ni una analogía con una pelota rodando: es la solución de un problema de minimización que se resuelve en una línea.

De ahí la regla de actualización, que es todo el algoritmo:


$$\mathbf{w}^{k+1} = \mathbf{w}^k - \alpha \nabla g(\mathbf{w}^k), \quad k = 0, 1, 2, \dots$$

Cómo se lee. Se parte de un punto cualquiera y, en cada iteración, se da un paso en contra del gradiente. El número α —la tasa de aprendizaje— controla el tamaño del paso. El superíndice k cuenta iteraciones; no es una potencia.

Para el ECM el gradiente se calcula explícitamente y no hay nada que aproximar:

$$\nabla g(\theta) = \frac{2}{p} \mathbf{X}^\top (\mathbf{X}\theta - \mathbf{y}), \quad \nabla^2 g(\theta) = \frac{2}{p} \mathbf{X}^\top \mathbf{X} \succeq 0$$

Cómo se lee. A la izquierda, la fórmula del gradiente: se calculan los residuos y se combinan con las características. A la derecha, la matriz de segundas derivadas, que resulta ser semidefinida positiva — y eso, ni más ni menos, es la demostración de que este costo es convexo. Por eso, aquí, todo mínimo local es global.




Sesenta iteraciones sobre el problema de los diez puntos. Cada círculo es una iteración; las curvas grises son las curvas de nivel del ECM. Los pasos se acortan solos al acercarse al mínimo, porque el gradiente se anula ahí. Trayectoria calculada, no dibujada.

La tasa de aprendizaje no es un detalle

El paso α es el único parámetro del método, y decide entre converger, arrastrarse o divergir. Para un costo cuadrático el resultado es exacto y se puede enunciar sin ambigüedad: si la matriz de segundas derivadas es definida positiva, el método converge al mínimo *si y solo si*

$$0 < \alpha < \frac{2}{\lambda_{\max}(\mathbf{H})}, \quad \mathbf{H} = \nabla^2 g$$

Cómo se lee. El paso admisible está acotado por el mayor valor propio de la matriz de segundas derivadas, que mide la curvatura máxima del costo. Cuanto más curvo el paisaje, más corto debe ser el paso. Pasar ese umbral no significa converger más despacio: significa alejarse del mínimo en cada iteración.



Tres tasas sobre el mismo problema, con el mismo punto de partida. Aquí $L = 28,76$, de modo que el umbral de divergencia está en $2/L = 0,0696$. Con $\alpha = 2,05/L$ el método se aleja del mínimo, y el costo crece más de diez órdenes de magnitud en cuarenta iteraciones. Cálculo propio.

Para costos generales el enunciado correcto exige hipótesis, que conviene declarar antes que afirmar de más. Si el costo es diferenciable y su gradiente es Lipschitz con constante L , y el paso cumple $0 < \alpha \leq 1/L$, entonces cada iteración garantiza un descenso suficiente:

$$g(w^{k+1}) \leq g(w^k) - \frac{\alpha}{2} \|\nabla g(w^k)\|^2$$

Cómo se lee. El costo baja en cada paso, y baja al menos tanto como indica el tamaño del gradiente. Consecuencia inmediata: los gradientes tienden a cero. Ojo con lo que esto no dice — garantiza acercarse a un punto donde el gradiente se anula, no al mejor de todos ellos.

Si además el costo es convexo, se obtiene una cota sobre la distancia al valor óptimo que decrece como el inverso del número de iteraciones; y si es fuertemente convexo, la convergencia pasa a ser geométrica. Sin convexidad —el caso de las redes neuronales— no hay garantía de alcanzar el mínimo global: solo un punto estacionario.

Este es el punto donde más se peca al divulgar: decir "el descenso del gradiente encuentra el mínimo" es falso sin hipótesis. Con convexidad, es cierto. Sin ella, lo que se encuentra es un punto donde el gradiente se anula, que puede no ser el mejor.

El escalado de las características no es cosmético

Hay un factor que decide la velocidad del método y que no aparece en la regla de actualización: la forma del paisaje. Se mide con el número de condición de la matriz de segundas derivadas, el cociente entre su mayor y su menor valor propio.

$$\kappa(\mathbf{H}) = \frac{\lambda_{\max}(\mathbf{H})}{\lambda_{\min}(\mathbf{H})} \geq 1$$


Cómo se lee. Si vale 1, las curvas de nivel son circunferencias y el gradiente apunta directamente al mínimo. Cuanto mayor es, más alargadas son las elipses y más oblicuo resulta el gradiente respecto de la dirección que de verdad lleva al mínimo.

Para un costo cuadrático estrictamente convexo, y eligiendo en cada iteración el paso óptimo por búsqueda exacta, la desigualdad de Kantorovich da la tasa de convergencia en función de ese único número:

$$g(\theta^{k+1}) - g^* \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^2 (g(\theta^k) - g^*)$$

Cómo se lee. La distancia al valor óptimo se multiplica en cada paso por un factor que depende solo del condicionamiento. Con $\kappa = 1$ ese factor es cero —se llega en un paso—; con $\kappa = 100$ vale aproximadamente 0,96, y hacen falta cientos de iteraciones para ganar unos pocos dígitos.

El punto práctico es que ese número no viene dado por el problema: depende de las unidades en que midamos las características. Y hay algo que conviene subrayar para no confundir dos cosas distintas: centrar y escalar es un cambio de parametrización, no un cambio de modelo. Como la transformación es afín e invertible y el modelo incluye término independiente, el espacio de funciones representables es el mismo y la recta ajustada, deshecho el cambio, es idéntica. Lo único que cambia —y cambia mucho— es la geometría que ve el algoritmo.



El mismo problema de diez puntos, con las mismas ecuaciones y el mismo paso $\eta = 1/L$, en dos parametrizaciones. Sin escalar, el número de condición es 92,11 y hacen falta 855 iteraciones para que la diferencia con el costo óptimo baje del 10% relativo. Estandarizadas, el número de condición es exactamente 1 y el método llega al mínimo en una sola iteración. Cálculo propio.

Cuando alguien reporta que "el descenso del gradiente no converge", muchas veces el problema no está en el algoritmo ni en la tasa de aprendizaje, sino en que las características se midieron en escalas incomparables.

La variante estocástica

Cuando P es grande, evaluar el gradiente completo en cada iteración —lo que exige recorrer todas las observaciones— resulta caro. La variante estocástica usa en cada paso un subconjunto pequeño elegido al azar:

$$\mathbf{w}^{k+1} = \mathbf{w}^k - \alpha_k \frac{1}{|\mathcal{B}_k|} \sum_{p \in \mathcal{B}_k} \nabla L_p(\mathbf{w}^k)$$

Cómo se lee. En lugar del gradiente exacto se usa el promedio sobre un lote pequeño de observaciones tomadas al azar. Si el lote se elige uniformemente, ese promedio es un estimador insesgado del gradiente verdadero: en promedio

apunta bien, aunque en cada paso concreto se desvíe.

El precio es que la trayectoria deja de ser monótona: el costo puede subir en algunas iteraciones. Para compensar el ruido, la tasa se reduce a lo largo del proceso, y las condiciones clásicas de Robbins y Monro que aseguran la convergencia son:

$$\sum_{k=1}^{\infty} \alpha_k = \infty, \quad \sum_{k=1}^{\infty} \alpha_k^2 < \infty$$

Cómo se lee. La primera condición exige que los pasos sumen infinito: de lo contrario el método podría detenerse antes de llegar. La segunda exige que los cuadrados sumen finito: los pasos deben achicarse lo bastante rápido como para que el ruido se apague. Una sucesión que cumple ambas es $\alpha_k = 1/k$.

QUÉ ALGORITMO USA CADA MÉTODO CLÁSICO — Y POR QUÉ NO TODOS USAN GRADIENTE

El descenso del gradiente es el método de primer orden canónico y el que sostiene todo lo que vino después, pero sería inexacto decir que es el algoritmo del aprendizaje automático clásico. Aplica a cualquier costo diferenciable; varios métodos clásicos no lo necesitan o no lo admiten.

MÉTODO	CÓMO SE AJUSTA	¿USA GRADIENTE?
Regresión lineal (ECM)	Ecuaciones normales, solución cerrada; o descenso si N es grande.	Opcional
Regresión logística	No hay solución cerrada: métodos iterativos de primer o segundo orden.	Sí
Máquinas de soporte vectorial	Programación cuadrática con restricciones (formulación dual).	No en su forma clásica
Árboles de decisión	Partición recursiva voraz maximizando una ganancia por corte.	No: el criterio no es diferenciable
k vecinos más cercanos	No hay entrenamiento: el modelo son los propios datos.	No
Naive Bayes	Estimación por máxima verosimilitud, en forma cerrada.	No
k-medias (no supervisado)	Algoritmo de Lloyd: alternar asignación y recálculo de centroides.	No

La tabla también explica por qué el descenso del gradiente merece el espacio que se le da: es el único de la lista que no depende de la forma particular del modelo. Mientras el costo sea diferenciable, el mismo procedimiento sirve — y esa generalidad es la razón de que las redes neuronales, que rompen todas las demás recetas, sigan entrenándose con él.

Los dos problemas predictivos

Lo que cambia no es el algoritmo: es el conjunto donde vive la salida

Con las cuatro piezas en su sitio, la clasificación de los problemas predictivos es casi trivial de enunciar. Si la salida es una cantidad continua, el problema es de regresión. Si toma valores en un conjunto finito de clases, es de clasificación. El modelo lineal es el mismo en ambos casos; lo que cambia es lo que se hace con su resultado y , en consecuencia, la función de costo.

En clasificación binaria, con las clases codificadas como -1 y $+1$, la predicción es el signo, y la frontera es el hiperplano donde la expresión se anula:


$$\hat{y} = \text{sign}(b + x^\top w), \quad \mathcal{H} = \{x \in \mathbb{R}^N : b + x^\top w = 0\}$$

Cómo se lee. Se evalúa la misma expresión lineal y se mira únicamente su signo: positivo, una clase; negativo, la otra. El conjunto de puntos donde la expresión vale cero es la frontera de decisión, que separa el espacio en dos regiones.

Aquí aparece un problema técnico interesante. Lo que quisiéramos minimizar es el número de errores, es decir la pérdida 0-1; pero esa función es discontinua y no convexa, y minimizarla directamente es computacionalmente intratable. La salida clásica consiste en sustituirla por una cota superior convexa, que sí se puede minimizar. Con el margen $m = y \cdot f(x)$, que es positivo exactamente cuando la predicción acierta:

$$L_{0-1}(m) = \mathbf{1}\{m \leq 0\}, \quad L_{\log}(m) = \log(1 + e^{-m}), \quad L_{\text{bis}}(m) = \max\{0, 1 - m\}$$

Cómo se lee. La primera cuenta errores: vale 1 si se falló y 0 si se acertó. Las otras dos son sustitutas suaves y convexas que castigan también los aciertos "por poco". La logística da lugar a la regresión logística; la de bisagra, a las máquinas de soporte vectorial. Dos métodos que se estudian por separado difieren, en el fondo, en qué función eligieron para reemplazar el conteo de errores.



La función escalonada es lo que de verdad importa —el error de clasificación—, pero no se puede optimizar. Las otras dos la acotan por arriba y sí son convexas. Curvas calculadas a partir de sus definiciones.

Los ejemplos del capítulo, ordenados

El texto reúne una colección de aplicaciones que vale la pena leer junta, porque hace evidente que la distinción entre ambos problemas no depende del área ni de la tecnología, sino de la naturaleza de la salida.

APLICACIÓN	QUÉ SE PREDICE	TIPO
------------	----------------	------

Precio de la acción de una empresa que sale a bolsa	Un precio, a partir de los ingresos	Regresión
Deuda estudiantil total en Estados Unidos	Un monto, a partir del tiempo	Regresión
Taquilla de una película en su fin de semana de estreno	Ingresos, a partir del volumen de búsquedas y menciones	Regresión
Estudios de asociación del genoma completo	Un rasgo cuantitativo —colesterol, glucosa— a partir de marcadores genéticos	Regresión
Detección de rostros en una imagen	Rostro o no rostro, en cada posición de una ventana deslizante	Clasificación
Lectura automática de dígitos manuscritos	Una de diez clases	Clasificación
Análisis de sentimiento en redes sociales	Opinión favorable o desfavorable, a partir de texto	Clasificación
Microarreglos de ADN	Predisposición genética a un cáncer, a partir de niveles de expresión génica	Clasificación
Imágenes de resonancia magnética funcional	Presencia o ausencia de un trastorno neurológico	Clasificación

Dos de estos casos merecen una advertencia que el propio texto insinúa y que conviene hacer explícita: en aplicaciones médicas, un clasificador entrenado sobre datos de una población no es directamente válido en otra, y el costo de un falso negativo no es el mismo que el de un falso positivo. Nada de eso está en el ECM ni en la tasa de aciertos: hay que ponerlo explícitamente en la función de costo.

Queda una pregunta natural: ¿y si hay más de dos clases? Los dígitos manuscritos son diez. Una sola recta no basta, y las salidas clásicas son dos: reducir el problema a varios binarios —uno contra todos, o uno contra uno— o tratar todas las clases a la vez con una generalización de la regresión logística. Ambas se desarrollan en la literatura estándar; quedan señaladas aquí para no dejar la impresión de que la clasificación termina en el caso binario.

Cómo se evalúa un clasificador

En regresión el desempeño se resume con el ECM. En clasificación no basta un solo número, y conviene decir por qué. Todo empieza por contar los cuatro casos posibles al comparar la predicción con la verdad.

MATRIZ DE CONFUSIÓN		
	predice positivo	predice negativo
es positivo	Verdaderos positivos (VP)	Falsos negativos (FN)
es negativo	Falsos positivos (FP)	Verdaderos negativos (VN)

Los cuatro recuentos de los que se derivan todas las métricas de clasificación. Esquema propio.

De esos cuatro números salen las medidas habituales. La primera es la proporción de aciertos; las otras dos miran cada una un tipo distinto de error:

$$\begin{aligned} \text{exactitud} &= \frac{VP + VN}{VP + VN + FP + FN} & \text{precisión} &= \frac{VP}{VP + FP} \\ \text{sensibilidad} &= \frac{VP}{VP + FN} \end{aligned}$$

Cómo se lee. La exactitud es la fracción de casos bien clasificados. La precisión responde: de todo lo que marqué como positivo, ¿cuánto lo era de verdad? La sensibilidad responde la pregunta contraria: de todo lo que era positivo, ¿cuánto logré marcar? Son preguntas distintas y ninguna implica la otra.

Y aquí está la razón por la que la exactitud, que es la métrica que todo el mundo cita, puede ser engañosa. Supongamos una enfermedad presente en el 1 % de la población y un clasificador que responde "sano" en todos los casos, sin mirar nada. Sobre 1000 personas obtiene 990 aciertos: exactitud del 99 %. Su sensibilidad, en cambio, es cero —no detectó a ninguno de los 10 enfermos— y su precisión ni siquiera está definida, porque el denominador es cero. Un modelo inútil con una cifra excelente.

Con clases desbalanceadas, la exactitud puede ser alta y el modelo, inservible.

Cuando se quiere un solo número que no se deje engañar tan fácilmente, se combinan precisión y sensibilidad con su media armónica:

$$F_1 = 2 \cdot \frac{\text{precisión} \cdot \text{sensibilidad}}{\text{precisión} + \text{sensibilidad}}$$


Cómo se lee. La media armónica se acerca siempre al menor de los dos valores, de modo que solo es alta cuando ambos lo son. En el ejemplo anterior daría cero.

La elección entre estas medidas no es estadística sino del problema: en un tamizaje médico, dejar pasar un enfermo cuesta mucho más que una alarma falsa; en un filtro de correo no deseado ocurre lo contrario. Esa asimetría se lleva a la práctica ponderando las clases dentro de la función de costo, o moviendo el umbral de decisión — que no tiene por qué ser el cero.

Supervisado y no supervisado

Toda la diferencia está en una letra

La distinción suele explicarse con listas de algoritmos, y eso la vuelve más confusa de lo que es. La diferencia es una sola y es estructural: si el dato incluye o no la variable de salida. Todo lo demás se deduce de ahí, incluida la consecuencia más incómoda: sin etiqueta no hay una noción objetiva de error.



A la izquierda conozco la clase de cada punto y puedo contar cuántos quedaron del lado equivocado. A la derecha solo tengo la nube: los grupos son una lectura de su geometría, no una respuesta verificable. Ilustración conceptual.


	SUPERVISADO	NO SUPERVISADO
El dato	$\mathcal{D} = \{(x_p, y_p)\}_{p=1}^P$	$\mathcal{D} = \{x_p\}_{p=1}^P$
El objetivo	Predecir la salida de una observación nueva.	Describir la estructura: agrupar, reducir la dimensión, estimar la densidad.
El error	Medible: se compara la predicción contra la salida verdadera.	No hay error de predicción; la evaluación usa criterios internos.
Ejemplos	Diagnóstico a partir de atributos citológicos; detección de rostros; pronóstico de demanda.	Segmentación de clientes; agrupamiento de documentos por tema; reducción de dimensión antes de visualizar.

Un ejemplo concreto: k-medias

El método no supervisado más conocido ilustra bien en qué cambia el planteamiento. El objetivo se escribe como un problema de optimización, igual que antes, pero lo que se minimiza ya no involucra ninguna etiqueta:

$$\min_{\{C_1, \dots, C_k\}} \sum_{j=1}^k \sum_{x \in C_j} \|x - \mu_j\|^2, \quad \mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$$

Cómo se lee. Se busca repartir los puntos en k grupos de manera que la suma de las distancias al cuadrado de cada punto al centro de su grupo sea lo más pequeña posible. El centro de cada grupo es simplemente el promedio de sus miembros.



k-medias con $k = 3$ sobre 62 puntos generados con tres centros. A la izquierda, lo único que recibe el algoritmo. A la derecha, la partición a la que llegó y sus centroides. Cálculo propio: algoritmo de Lloyd hasta estabilizarse.

Y aquí hay que ser honesto con dos cosas que suelen omitirse. Primero: encontrar el óptimo global de ese problema es NP-difícil en general; el algoritmo de Lloyd —lo que todo el mundo llama "k-medias"— garantiza únicamente un óptimo local, y el resultado depende de la inicialización. Segundo: el número k lo elige la persona, no los datos. Existen criterios para orientar esa elección, pero ninguno es una respuesta verdadera en el sentido en que sí lo es una etiqueta.

Sin etiqueta no hay error que medir; y sin error que medir, la evaluación deja de ser una verificación y pasa a ser un juicio. Eso no invalida el método: obliga a declarar el criterio.

Una precisión sobre las fuentes: el capítulo introductorio que sirve de base a este documento trata únicamente el aprendizaje predictivo —regresión y clasificación—, que es supervisado en ambos casos, y no define el no supervisado. Esa parte proviene de Hastie, Tibshirani y Friedman, y de Bishop, referenciados al final.

El agrupamiento no agota lo no supervisado. La otra gran familia es la reducción de dimensión, cuyo representante clásico es el análisis de componentes principales: en vez de agrupar observaciones, busca las direcciones a lo largo de las cuales los datos varían más, y proyecta sobre ellas. Tiene una particularidad que lo hace especialmente grato de estudiar para alguien que viene del álgebra lineal: no requiere ningún algoritmo iterativo, porque esas direcciones son exactamente los vectores propios de la matriz de covarianza, ordenados por sus valores propios.

El proceso completo

Las cinco etapas del libro, leídas contra el estándar CRISP-DM

El texto resume el camino completo en cinco etapas, numeradas de 0 a 4, y advierte que son las mismas para esencialmente cualquier problema de aprendizaje automático.



si el desempeño es pobre, se vuelve atrás

En azul, la etapa que el propio texto trata como la más determinante, y la que menos atención suele recibir fuera de los libros.

0. Definir el problema. Precisar la tarea y, sobre todo, qué es la salida: de su naturaleza depende que el problema sea de regresión o de clasificación.

1. Recolectar los datos. Reunir el conjunto de entrenamiento y el de prueba, que deben ser disjuntos. Cuanto más grande y diverso el entrenamiento, más experiencia tiene el modelo de la variedad real del problema.

2. Diseñar las características. Elegir la aplicación que lleva el dato crudo al vector de características. No se trabaja con los píxeles de la imagen, sino con atributos extraídos de ella.


3. Entrenar el modelo. Resolver el problema de minimización planteado por las tres primeras piezas, mediante el algoritmo que constituye la cuarta.

4. Probar el modelo. Evaluar sobre el conjunto de prueba, extrayendo de cada dato nuevo las mismas características. Si el desempeño es pobre, se vuelve atrás.

Dos observaciones sobre la numeración, que no es un capricho editorial. La primera es que empieza en cero: definir el problema no es una etapa más, es la condición para que las demás signifiquen algo. La segunda es que el modelo aparece en la etapa 3 de cinco; antes de él hay tres decisiones —qué se predice, con qué datos y con qué representación— que condicionan todo lo que venga después. La discusión pública sobre el tema, sin embargo, se concentra casi por completo en esa etapa 3.

La misma idea, en el estándar de la industria

Fuera del aula, el proceso rara vez se llama así. La referencia habitual es CRISP-DM —*Cross-Industry Standard Process for Data Mining*—, publicada en 2000 y todavía la metodología más usada en proyectos de datos. Son seis fases y, como el esquema del libro, es cíclica: se vuelve atrás tantas veces como haga falta.



En azul, las dos fases que el capítulo del libro desarrolla en detalle

Las seis fases de CRISP-DM. Esquema propio a partir de la guía publicada por el consorcio en 2000.

La correspondencia entre ambos esquemas es instructiva, pero no es una biyección, y presentarla como tal sería inexacto. Conviene mostrarla con la columna de las diferencias a la vista:

ETAPA DEL LIBRO	FASE DE CRISP-DM	QUÉ NO COINCIDE
0. Definir el problema	Comprensión del negocio	CRISP-DM incluye objetivos de negocio, criterios de éxito y plan de proyecto; el libro solo pide precisar la tarea.
1. Recolectar los datos	Comprensión de los datos	CRISP-DM añade la exploración y la verificación de calidad, que el libro no menciona.
2. Diseñar las características	Preparación de los datos	No es una fase propia en CRISP-DM: vive dentro de la preparación, junto con limpieza, integración y formateo.
3. Entrenar el modelo	Modelado	Correspondencia directa. CRISP-DM explicita además la elección de técnica y el diseño de la prueba.
4. Probar el modelo	Evaluación	En CRISP-DM la evaluación es contra los objetivos de negocio, no solo contra el error del conjunto de prueba.
— sin equivalente —	Despliegue	El libro no lo contempla: puesta en producción, monitoreo, mantenimiento y documentación quedan fuera de su esquema.

La ausencia más significativa está en la última fila. Un modelo que funciona en el cuaderno y nunca llega a producción no resolvió ningún problema; y uno que llegó y no se monitorea envejece en silencio, porque los datos del mundo cambian aunque el modelo no.


El diseño de características

Por qué la representación decide más que el modelo

El ejemplo que mejor explica la etapa 2 tiene casi cuatro siglos. Galileo dejó rodar una bola por una rampa y midió cuánto tardaba en recorrer cada fracción del trayecto. Si se grafica la distancia contra el tiempo, los puntos describen una parábola y ninguna recta los ajusta. Si se grafica contra el tiempo al cuadrado, quedan alineados.

$$d(t) = \frac{1}{2} a t^2 \implies d = \frac{a}{2} u \quad \text{con} \quad u = t^2$$

Cómo se lee. La distancia recorrida crece con el cuadrado del tiempo. Si en vez del tiempo usamos el tiempo al cuadrado como variable, la misma relación se vuelve una recta que pasa por el origen y cuya pendiente es la mitad de la aceleración. La ley no cambió: cambió la variable con la que se la mira.



La misma ley física en dos representaciones. Curvas generadas a partir de la ecuación, no de mediciones.

Esto es exactamente lo que en aprendizaje automático se llama diseñar una característica. Y hay un punto fino, que es donde suele perderse el rigor: no se cambió de familia de modelos. El modelo siguió siendo lineal — lineal en la nueva variable. Un modelo lineal es lineal *en los parámetros*, no necesariamente en las variables originales, y esa distinción es la que permite que la regresión lineal ajuste curvas sin dejar de ser lineal.


De ahí se sigue que la calidad de una característica no es una propiedad absoluta, sino relativa al problema. El texto lo ilustra con un ejemplo preciso: el número de patas no distingue un gato de un perro, pero distingue perfectamente un gato de una serpiente. Y la elección depende de cuánto entendamos el fenómeno: en el caso de Galileo, el conocimiento de la física dictó la característica; en visión por computador, donde no entendemos igual de bien el proceso, hubo que conformarse con detectar bordes.

Diseñar características es traducir lo que uno entiende del fenómeno a algo que el modelo pueda ver. Por eso el conocimiento del dominio no es un adorno del proyecto: es una entrada del proyecto.

Cuando el modelo falla

Dos maneras distintas de equivocarse, y por qué conviene no confundirlas


El capítulo cierra su ejemplo con un fracaso, y conviene detenerse en él más que en los aciertos. Entre las imágenes de prueba hay un terrier de Boston: nariz pequeña, orejas puntiagudas. El modelo lo clasifica como gato.



Un solo punto del lado equivocado, y ninguna culpa del algoritmo. Ilustración conceptual.

Vale la pena ser preciso sobre la causa, porque es fácil atribuirlo al lugar equivocado. No falló la pieza 4: la optimización resolvió correctamente el problema que le plantearon. Tampoco falló la pieza 2: dentro de la familia lineal, esa era la mejor recta posible para esos datos. Falló la representación —la pieza 2 del proceso, no del modelo—, inducida por un conjunto de entrenamiento pequeño y poco diverso en el que dos características bastaban para separar las clases. La corrección no es cambiar de algoritmo: es volver a la etapa 1.

El segundo modo de fallar es distinto y más traicionero, porque no se manifiesta como un error: se manifiesta como un éxito. Un modelo suficientemente flexible puede ajustar los datos de entrenamiento hasta el punto de reproducir también su ruido. El error de entrenamiento baja; el error real sube. Es el sobreajuste, y es la manifestación práctica del intercambio entre sesgo y varianza de la sección II.3.



Veinte puntos generados a partir de una senoide más ruido normal. A la izquierda, tres ajustes polinómicos: el de grado 1 es demasiado rígido; el de grado 15 pasa cerca de cada punto y oscila sin sentido entre ellos. A la derecha, el error en entrenamiento no deja de bajar mientras el error en prueba se dispara. Cálculo propio sobre datos sintéticos.

La figura contiene la lección más importante de todo el documento, y por eso queda para el final: el error de entrenamiento no es una medida de calidad. Es una cantidad que se puede llevar a cero con solo agregar parámetros, y hacerlo empeora el modelo. El único número que informa algo es el error sobre datos que no participaron del ajuste — lo cual devuelve, en línea recta, a la definición de aprendizaje de la sección I.

Sabemos que el modelo aprendió cuando acierta con lo que nunca vio. Todo lo demás —el ECM sobre el entrenamiento, la recta que pasa por todos los puntos, el ajuste perfecto— puede ser, literalmente, la evidencia de lo contrario.

Las herramientas para controlar el sobreajuste exceden el alcance de esta edición y quedan aquí solo enunciadas: partición en entrenamiento, validación y prueba; validación cruzada; y regularización, que consiste en agregar al costo un término que penaliza la complejidad. Cada una exige el mismo detalle que el resto del documento y se tratará por separado.

Sí conviene dejar anotado cómo se detecta el problema, porque es puramente operativo y se desprende de la figura: lo que delata el sobreajuste no es el valor del error de entrenamiento, sino la brecha entre ese error y el de prueba. Un error de entrenamiento bajo con una brecha grande indica un modelo que memorizó; dos errores altos y parecidos indican lo contrario, una familia demasiado rígida para el fenómeno. Son diagnósticos distintos y piden correcciones opuestas, y confundirlos lleva a agregar complejidad justo cuando había que quitarla.

Una advertencia final sobre la palabra "complejidad", que en la figura aparece medida por el grado del polinomio: el número de parámetros es una medida cómoda, pero no es la definición. Dos modelos con el mismo número de parámetros pueden tener capacidades muy distintas, y existen formas más finas de medirla. La advertencia evita dejar instalada una equivalencia útil como intuición y falsa como enunciado.

Notación empleada

SÍMBOLO	SIGNIFICADO
P	Número de observaciones del conjunto de entrenamiento.
N	Número de características que describen cada observación.
$x_p \in \mathbb{R}^N$	Vector de características de la observación p.
y_p	Salida verdadera de la observación p: un número real en regresión, una clase en clasificación.
X	Matriz de diseño: las observaciones apiladas por filas, con una columna inicial de unos.
b, w	Parámetros del modelo lineal: término independiente y vector de pesos.
$f(x)$	Modelo: la función que convierte características en predicción.
L, g	Pérdida sobre una observación y costo sobre todo el conjunto.
∇g	Gradiente del costo: vector de sus derivadas parciales.
α	Tasa de aprendizaje: longitud del paso en cada iteración.
$\star$	Marca el valor óptimo de un parámetro.

Glosario mínimo

Característica (feature). Cada uno de los números con los que se describe una observación. Diseñarlas es decidir qué se mide.

Conjunto de entrenamiento y de prueba. Los datos con los que se ajusta el modelo y los datos, distintos, con los que se lo evalúa.

Parámetro. Número interno del modelo que se ajusta durante el entrenamiento. Distinto de hiperparámetro, que se fija antes y no se aprende — la tasa de aprendizaje y el número de grupos en k-medias son hiperparámetros.

Función de costo. Número que resume qué tan mal se desempeña una elección de parámetros. Entrenar es hacerlo lo más pequeño posible.

Convexidad. Propiedad de una función que garantiza que no tiene mínimos locales distintos del global. Cuando se cumple, encontrar el mejor ajuste es un problema resuelto; cuando no, no hay garantías.

Gradiente. Vector que indica la dirección de máximo crecimiento de una función. Su opuesto es la dirección en la que conviene moverse para minimizarla.

Sobreajuste. Situación en la que el modelo memoriza los datos de entrenamiento, ruido incluido, y por eso funciona peor con datos nuevos.

Sesgo y varianza. Las dos fuentes de error que sí dependen del modelo: la rigidez de la familia elegida y la inestabilidad del ajuste frente a cambios en la muestra.

Número de condición. Cociente entre la mayor y la menor curvatura del costo. Mide qué tan alargadas son sus curvas de nivel y, con ello, qué tan lento avanza el descenso del gradiente.

Precisión y sensibilidad. Dos maneras complementarias de evaluar un clasificador: qué proporción de lo marcado como positivo lo era, y qué proporción de los positivos reales fue marcada. Ninguna implica la otra.

Qué es cada cosa en este documento

El texto de base es el capítulo 1 de *Machine Learning Refined*. Ese capítulo es expositivo y no usa notación: toda la formulación simbólica de este documento es propia, y hace explícito lo que allí se dice en palabras. Los contenidos que no están en esa fuente —la definición de aprendizaje no supervisado, las condiciones de convergencia del descenso del gradiente, la descomposición sesgo-varianza, el número de condición y su tasa de convergencia, las métricas de evaluación de clasificadores, la equivalencia con máxima verosimilitud y la metodología CRISP-DM— provienen de las referencias listadas abajo y están señalados en el punto donde aparecen.

Sobre las figuras. Las de gatos y perros son ilustraciones conceptuales: no representan datos reales. Las de las secciones II y VII provienen de cálculos propios sobre datos sintéticos generados con semilla fija —mínimos cuadrados, iteraciones del descenso del gradiente, algoritmo de Lloyd y ajustes polinómicos—, de modo que los valores citados en los pies de figura son reproducibles. Las de la sección VI se generaron a partir de la ecuación del movimiento uniformemente acelerado, no de mediciones de Galileo. Los diagramas de las secciones II y V son esquemas propios.

Sobre los enunciados. Todo resultado matemático aparece con sus hipótesis. Donde una afirmación frecuente es imprecisa —"el descenso del gradiente encuentra el mínimo", "el algoritmo del aprendizaje automático clásico es el descenso del gradiente"— se dice expresamente en lugar de simplificar. Esta es una edición en curso: se ampliará con los temas que quedaron enunciados y no desarrollados.

REFERENCIAS

- Watt, J., Borhani, R. y Katsaggelos, A. *Machine Learning Refined*. Cambridge University Press. Capítulo 1.
- Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning* (2.ª ed.). Springer. Caps. 2, 7 y 14.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer. Caps. 1, 3 y 9.
- Boyd, S. y Vandenberghe, L. (2004). *Convex Optimization*. Cambridge University Press. Cap. 9.
- Nocedal, J. y Wright, S. (2006). *Numerical Optimization* (2.ª ed.). Springer. Caps. 1 y 3.
- Robbins, H. y Monro, S. (1951). A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3), 400–407.
- Chapman, P. et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- Nussbaumer Knaflic, C. (2015). *Storytelling with Data*. Wiley.

Luis Javier Rubio Hernández